

Introducción

La gestión de residuos es un desafío ambiental crítico. La separación manual suele ser ineficiente por errores humanos o falta de infraestructura. Presentamos un sistema integral que combina Visión Artificial con un prototipo robótico para automatizar la clasificación en origen. El sistema identifica y separa físicamente residuos en 4 categorías: Cartón/Papel, Metal/Plástico, Basura general y “Ecoglasses” (vasos reutilizables), utilizando una cámara estéreo y un mecanismo accionado por Arduino.

Objetivos

- Desarrollar un clasificador de imágenes robusto basado en MobileNetV3-Large mediante Transfer Learning.
- Integrar el modelo de Deep Learning con un sistema físico de actuación robótica (2 Grados de Libertad).
- Gestionar un dataset híbrido combinando datos públicos (Kaggle) con datos propios (Ecoglasses).
- Alcanzar una inferencia en tiempo real apta para hardware de recursos limitados.

Datos y Preprocesamiento

Datasets utilizados (Total: 14,094 imágenes)

- Garbage Classification Dataset (Kaggle)*: 14k imágenes agrupadas en: *cardboard_paper*, *metal_plastic*, y *trash*.
- Dataset Propio (Ecoglasses)*: 98 imágenes capturadas en el entorno real del prototipo.

Data Augmentation (Albumentations) Para mitigar el desbalance de clases y mejorar la robustez, se aplicó un pipeline agresivo:

Transformación	Parámetros
RandomResizedCrop	Escala 0.8–1.2
Rotación	$\pm 15^\circ$
Color Jitter	Brillo, Contraste, Sat ($p = 0,5$)
Ruido Gaussiano	Robustez ante sensores

Se redimensionó a 224×224 y se normalizó con estadísticas de ImageNet.

Grad-CAM

Para profundizar en las causas de la caída de rendimiento en el dataset externo (58.9 % de accuracy), utilizamos la técnica Grad-CAM para visualizar qué regiones de la imagen activan la red neuronal.




Figura 1: Prototipo con 2 servos y 4 contenedores.

Arquitectura del Modelo

Utilizamos MobileNetV3-Large pre-entrenada en ImageNet, ideal para inferencia eficiente.

Componentes Clave:

- Backbone:** Bloques Inverted Residual con módulos Squeeze-and-Excitation (SE).
- Clasificador:** Capas densas personalizadas para 4 clases, activación *HardSwish* y *Dropout* ($p = 0,2$).
- Entrenamiento:** Optimizador Adam, Loss CrossEntropy con *Label Smoothing* ($\epsilon = 0,1$).




Figura 2: Arquitectura MobileNetV3 con clasificador personalizado.

Integración Robótica (HW/SW)

El sistema realiza inferencia en una laptop y envía comandos vía Serial a un Arduino Nano.

Flujo de Actuación:

- Inferencia:** Detección de clase ($> 80\%$ confianza).
- Comunicación:** Envío de byte (0x00-0x03) al Arduino.
- Servo Base:** Rota $\pm 45^\circ$ para elegir par de contenedores.
- Servo Plataforma:** Inclina $\pm 40^\circ$ para depositar.




Figura 3: Prototipo con 2 servos y 4 contenedores.




Figura 4: Prototipo con 2 servos y 4 contenedores.

Resultados Experimentales

Métricas (Epoca 30)

Métrica	Valor
Val Acc	96.9 %
Val F1	97.6 %
Train Acc	98.8 %

Convergencia estable sin overfitting severo.




Figura 5: Curvas de Loss y F1.

Matriz Confusión

R\P	C/P	Eco	M/P	Tr
Card	97.8	0.1	1.2	0.9
Eco	0.0	98.7	1.3	0.0
M/P	0.8	0.2	95.9	3.1
Trash	1.1	0.0	3.2	95.7

(3.2 %) en Metal/Trash.

Conclusiones

- Precisión $> 96\%$ valida Transfer Learning.
- Clase *Ecoglasses* bien clasificada por contexto.
- Viabilidad de automatización Low-Cost demostrada.

Referencias

- Zlatan599, “Garbage Classification Dataset,” Kaggle, n.d. [Online]. Available: <https://www.kaggle.com/datasets/zlatan599/garbage-dataset-classification>
- A. Buslaev et al., “Albumentations: Fast and flexible image augmentations,” Information, vol. 11, no. 2, p. 125, 2020.
- K. He et al., “Deep Residual Learning for Image Recognition,” in Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR), 2016, pp. 770–778.