


Clasificación Automática de Residuos mediante Visión Artificial y Actuación Robótica

Tomás Benavidez Esposito (tbenavidez@udesa.edu.ar)
Naomi Couriel (ncouriel@udesa.edu.ar)



Introducción

La gestión ineficiente de residuos es un problema global. Presentamos un sistema *end-to-end* que integra:

1. **Visión Artificial:** MobileNetV3 optimizada.
2. **Robótica:** Separación física de bajo costo.

Clasifica: *Cartón/Papel, Metal/Plástico, Basura* y la clase personalizada “*Ecoglasses*”.

Objetivos

- Desarrollar clasificador robusto (Transfer Learning).
- Integrar actuación física de 2 Grados de Libertad.
- Validar en entorno real con dataset híbrido.

Datos y Preprocesamiento

Dataset Híbrido (14,000 imgs)

- **Kaggle:** 13,907 imgs
6 clases → 3 mapeadas + Ecoglasses
- **Propio:** 93 imgs
“Ecoglasses” (fondo negro, condiciones reales)

Split: 70 % train / 15 % val / 15 % test

Augmentation (Albumentations): Pipeline agresivo para robustez en producción:

Técnica	Parámetros
RandomCrop	Escala 0.8–1.2
Rotación	$\pm 15^\circ$
Color Jitter	Brillo/Sat ($p = 0,5$)
Ruido Gauss	$\sigma = 10\text{--}50$

Interpretabilidad Grad-CAM

Utilizamos **Grad-CAM** para visualizar qué regiones de la imagen tienen mayor peso en la predicción del modelo.




Figura 1: Mapas de calor de activación. Rojo = alta importancia.

Permite validar que el modelo atiende a características relevantes y detectar dependencia en features no deseadas (reflejos, fondo).

Referencias

- [1] Howard, A., et al. (2019). *Searching for MobileNetV3*. ICCV.
- [2] Selvaraju, R. R., et al. (2017). *Grad-CAM: Visual Explanations from Deep Networks*. ICCV.
- [3] Zlatan599. (2020). *Garbage Classification Dataset*. Kaggle.

Arquitectura de Red

Seleccionamos **MobileNetV3-Large** por su eficiencia (30ms en CPU). Adaptamos el clasificador final para 4 clases.




Figura 2: Backbone con bloques Inverted Residual + SE y Clasificador personalizado con Dropout.

Integración Robótica

Prototipo Físico




Figura 3: Sistema de 2 Servos + Arduino.

Componentes: Arduino Nano R3 (ATmega328P, 16 MHz), 2x 450FBB (1.8 kg·cm), Cámara estéreo, Batería LiPo 7.4V 2S 1000mAh.

Comunicación y Control

Laptop ↔ Arduino (Serial USB 9600 baud).

Lógica de Actuación:

1. **Servo Base:** Rota $\pm 45^\circ$ (Izq/Der).
2. **Servo Plataforma:** Inclina $\pm 40^\circ$.
3. **Predicción → Cuadrante:**
 - Clase 0,1 → Izquierda
 - Clase 2,3 → Derecha

Estabilidad Temporal: Sistema acumula predicciones durante 4s con confianza $> 70\%$ antes de actuar, reduciendo falsos positivos en 95 %.

Resultados Experimentales

Curvas de Aprendizaje (30 épocas)




Figura 4: Convergencia estable sin overfitting.

Métricas y Matriz de Confusión

Métrica	Valor
Val Accuracy	96.9 %
Val F1-Macro	97.6 %
Train Accuracy	98.8 %

Real \ Pred	C/P	Eco	M/P	Tr
Cardboard	97.8	0.1	1.2	0.9
Ecoglasses	0.0	98.7	1.3	0.0
Metal/Plas	0.8	0.2	95.9	3.1
Trash	1.1	0.0	3.2	95.7

→ Mayor confusión (3 %) entre Plástico y Basura debido a texturas similares.

Conclusiones y Trabajo Futuro

- Sistema validado **96.9 %** Acc. en entorno controlado y solución de bajo costo viable para despliegue real.
- **Futuro:** Ampliar Ecoglasses (93 → 500+ imgs); Edge deployment (Jetson Nano, 10W).